NEXORA INSIGHT

Diagnóstico de dados

exemplo_vendas.csv · 05/11/2026

Contexto: Geral · Objetivo: Não informado

EXEMPLO SINTÉTICO — não representa uma empresa.

Resumo executivo

509 registros recebidos; 509 na base após correções; 509 válidos na métrica receita. O original permanece preservado.

- **Dados ausentes em 1 coluna(s) relevante(s)**: desconto_pct: 34 de 509 linhas sem valor (6,7%)
  Próxima ação: Confirmar com a origem dos dados se o campo é opcional e, quando não for, tornar o preenchimento obrigatório. Não preencher (imputar) valores sem um critério validado com a área responsável.
- **Registros duplicados**: 9 linhas idênticas a outra anterior (1,8% de 509). Linhas do arquivo: 502, 503, 504, 505, 506, 507, 508, 509, 510.
  Próxima ação: Confirmar com a origem se as linhas repetidas são legítimas. Se não forem, ligue "Excluir linhas duplicadas idênticas" para tirá-las dos cálculos e corrija a carga na fonte.
- **Mesma categoria escrita de formas diferentes**: regiao: "Sudeste" (195) · "sudeste" (26)
  Próxima ação: Padronizar o campo na origem com uma lista de valores permitida. Se as grafias representarem a mesma categoria, revise e confirme a unificação em Importação e configurações.
- **Valores inconsistentes ou fora do esperado**: data_pedido: 2 datas posteriores a hoje (linhas 151, 378)
  Próxima ação: Listar as linhas indicadas com a área responsável e classificar cada caso como erro ou evento real antes de corrigir ou excluir.
- **Valores atípicos em receita**: 55 de 509 valores de "receita" ficam fora das cercas de Tukey (-1.406 a 2.780).
  Próxima ação: Validar com a fonte os 5 maiores registros (linhas 333, 416, 167, 195, 499) antes de excluir. Relatar sempre mediana junto com a média.

Registros recebidos	Base após limpeza	Colunas disponíveis	Alertas de qualidade
509	509	10	9
Arquivo original	Exclusões detalhadas em Explorar Dados	Após os filtros aplicados	Verificações que merecem atenção

DISTRIBUIÇÃO DA MÉTRICA

receita

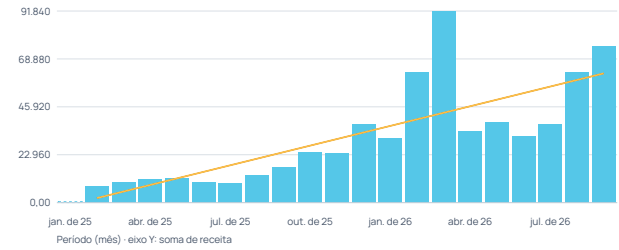
509 valores válidos; atípicos mantidos.



Fonte: exemplo_vendas.csv · Frequência por faixa de valor

EVOLUÇÃO TEMPORAL

receita por mês



Ciano: soma observada · tracejado: período parcial · âmbar: tendência descritiva.

Fonte: exemplo_vendas.csv · Soma por período · Barras tracejadas: períodos parciais

Confiabilidade dos dados

O que precisa ser verificado antes de confiar nos números.

Dados ausentes em 1 coluna(s) relevante(s)

Prioridade média

EVIDÊNCIA

- desconto_pct: 34 de 509 linhas sem valor (6,7%)

DESCOBERTA

- Os cálculos de cada coluna usam apenas as linhas preenchidas; o n válido de cada uma aparece na área Explorar Dados.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Não há evidência aqui de que a ausência seja aleatória. Ela pode vir de campo opcional, falha de integração ou dado não aplicável. Não foi testado.

IMPACTO POTENCIAL

Em "desconto_pct", 6,7% das linhas ficam fora do cálculo. Médias e somas dessa coluna descrevem só as linhas preenchidas e podem não representar o conjunto.

RECOMENDAÇÃO

Confirmar com a origem dos dados se o campo é opcional e, quando não for, tornar o preenchimento obrigatório. Não preencher (imputar) valores sem um critério validado com a área responsável.

> **Limitação:** Alertas de qualidade não comprovam erros: ausências e repetições podem ser legítimas. Confirme com a origem antes de corrigir.

Suporte amostral (regra prática, não certeza estatística): **maior** · n = 509; amostra grande para esta análise

Registros duplicados

Prioridade média

EVIDÊNCIA

- 9 linhas idênticas a outra anterior (1,8% de 509). Linhas do arquivo: 502, 503, 504, 505, 506, 507, 508, 509, 510.
- Identificador "id_pedido": 9 valores repetidos, dos quais 0 com conteúdo diferente entre as linhas.

DESCOBERTA

- Linhas com exatamente os mesmos valores em todas as colunas aparecem mais de uma vez.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Pode ser carga duplicada ou exportação repetida. Também pode ser repetição legítima, se o arquivo não tiver identificador único. Não dá para distinguir só com estes dados.

IMPACTO POTENCIAL

As duplicatas continuam incluídas nos cálculos (a exclusão está desligada). Somadas, essas linhas valem 7.041 em "receita" (1,1% do total sem duplicatas).

RECOMENDAÇÃO

Confirmar com a origem se as linhas repetidas são legítimas. Se não forem, ligue "Excluir linhas duplicadas idênticas" para tirá-las dos cálculos e corrija a carga na fonte.

> **Limitação:** Alertas de qualidade não comprovam erros: ausências e repetições podem ser legítimas. Confirme com a origem antes de corrigir.

Suporte amostral (regra prática, não certeza estatística): **maior** · n = 509; amostra grande para esta análise

Mesma categoria escrita de formas diferentes

Prioridade média

EVIDÊNCIA

- regiao: "Sudeste" (195) · "sudeste" (26)
- regiao: "Sul" (96) · "SUL " (8)

DESCOBERTA

- Os valores acima diferem só em maiúsculas, acentos ou espaços e permanecem distintos até a confirmação de uma correção de unificação.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- A origem provavelmente aceita texto livre nesse campo. Não verificado.

IMPACTO POTENCIAL

325 células estão em categorias com mais de uma grafia. As grafias continuam em grupos separados nesta análise; revise sua equivalência antes de consolidar totais.

RECOMENDAÇÃO

Padronizar o campo na origem com uma lista de valores permitida. Se as grafias representarem a mesma categoria, revise e confirme a unificação em Importação e configurações.

> **Limitação:** Alertas de qualidade não comprovam erros: ausências e repetições podem ser legítimas. Confirme com a origem antes de corrigir.

Suporte amostral (regra prática, não certeza estatística): **maior** · n = 509; amostra grande para esta análise

Valores inconsistentes ou fora do esperado

Prioridade média

EVIDÊNCIA

- data_pedido: 2 datas posteriores a hoje (linhas 151, 378)
- quantidade: 2 valores não numéricos (ex.: "dez") (linhas 58, 302)
- quantidade: 3 valores negativos (mín. -1)
- quantidade: Valor -1 aparece 3 vezes; pode ser código de "sem informação" (não confirmado)

DESCOBERTA

- Estes valores existem no arquivo. Textos em coluna numérica e datas inválidas não entram nos cálculos da coluna.
- Valores negativos e datas futuras foram mantidos; datas futuras são ignoradas apenas na série temporal.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Podem ser erro de digitação, ajuste legítimo (estorno, devolução) ou lançamento antecipado. Só quem conhece o processo pode dizer qual.

IMPACTO POTENCIAL

Somam 10 ocorrências de alerta (a mesma célula pode aparecer em mais de um alerta). Os cálculos das colunas envolvidas usam só os valores válidos, e a soma pode estar subestimada ou superestimada se esses registros forem relevantes.

RECOMENDAÇÃO

Listar as linhas indicadas com a área responsável e classificar cada caso como erro ou evento real antes de corrigir ou excluir.

> **Limitação:** Alertas de qualidade não comprovam erros: ausências e repetições podem ser legítimas. Confirme com a origem antes de corrigir.

Suporte amostral (regra prática, não certeza estatística): **maior** · n = 509; amostra grande para esta análise

Achados de negócio

Cada achado separa o que foi medido do que é hipótese.

Valores atípicos em receita

Prioridade alta

EVIDÊNCIA

- 55 de 509 valores de "receita" ficam fora das cercas de Tukey (-1.406 a 2.780).
- Maiores: 74.970 (linha 333), 45.497 (linha 416), 15.687 (linha 167), 6.361 (linha 195), 6.278 (linha 499).
- Média 1.270 com todos os valores; 677,7 sem os atípicos. Mediana: 479,4 e 454,9.

DESCOBERTA

- A média muda 87,4% quando os atípicos saem; a mediana muda 5,4%.
- Os atípicos somam 52,4% do total de "receita".

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Podem ser erro de digitação ou de unidade, ou vendas e eventos legítimos de grande porte. O app não tem como distinguir.
- Em distribuições assimétricas, o critério de Tukey marca como atípicos valores que são normais para o negócio.

IMPACTO POTENCIAL

As análises de grupo e tendência estão usando a base com esses 55 valores, que pesam 52,4% do total. A escolha muda os resultados.

RECOMENDAÇÃO

Validar com a fonte os 5 maiores registros (linhas 333, 416, 167, 195, 499) antes de excluir. Relatar sempre mediana junto com a média.

> **Limitação:** Comparação descritiva desta amostra. Composição dos grupos, valores ausentes e fatores externos podem explicar diferenças; não há comprovação causal.

Suporte amostral (regra prática, não certeza estatística): **maior** · n = 509; amostra grande para esta análise

Média de receita difere entre grupos de regiao

Prioridade baixa

EVIDÊNCIA

- "Sul": média 1.957, mediana 509,8, n=96, IC95% aprox. 423,6 a 3.489.
- "sudeste": média 806,0, mediana 624,9, n=26, IC95% aprox. 406,6 a 1.205.
- Diferença entre médias: 1.151. Grupos comparados: 5 com n ≥ 10 (de 6).

DESCOBERTA

- Os intervalos de confiança aproximados se sobrepõem: com esta amostra, não dá para descartar que a diferença seja acaso.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Uma diferença entre grupos não mostra o que a causa. Pode vir de mix de produtos, porte do cliente, período ou outras variáveis não incluídas. Nenhuma foi testada.
- A média é sensível aos 55 valores atípicos mantidos na base. Compare também as medianas (Sul: 509,8; sudeste: 624,9) ou ligue a exclusão de atípicos.
- 4 linhas sem "regiao" ficaram fora desta comparação.

IMPACTO POTENCIAL

A diferença de 1.151 entre as médias merece investigação de contexto antes de orientar decisões de gestão. Maior valor da métrica não significa melhor desempenho.

RECOMENDAÇÃO

Para decisões de gestão: investigar com a área responsável o que diferencia o grupo de maior média observada (processo, mix, público ou período) antes de replicar qualquer prática.

> **Limitação:** Comparação descritiva desta amostra. Composição dos grupos, valores ausentes e fatores externos podem explicar diferenças; não há comprovação causal.

Suporte amostral (regra prática, não certeza estatística): **baixa** · n = 26; amostra pequena, resultado muito instável

Média de receita difere entre grupos de canal

Prioridade alta

EVIDÊNCIA

- "Parceiro": média 2.832, mediana 1.123, n=115, IC95% aprox. 1.356 a 4.307.
- "Online": média 745,3, mediana 249,5, n=262, IC95% aprox. 587,5 a 903,0.
- Diferença entre médias: 2.086. Grupos comparados: 3 com n ≥ 10 (de 3).

DESCOBERTA

- Os intervalos de confiança aproximados não se sobrepõem: a diferença observada é maior do que a variação esperada só por amostragem, nesta base.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Uma diferença entre grupos não mostra o que a causa. Pode vir de mix de produtos, porte do cliente, período ou outras variáveis não incluídas. Nenhuma foi testada.
- A média é sensível aos 55 valores atípicos mantidos na base. Compare também as medianas (Parceiro: 1.123; Online: 249,5) ou ligue a exclusão de atípicos.

IMPACTO POTENCIAL

A diferença de 2.086 entre as médias merece investigação de contexto antes de orientar decisões de gestão. Maior valor da métrica não significa melhor desempenho.

RECOMENDAÇÃO

Para decisões de gestão: investigar com a área responsável o que diferencia o grupo de maior média observada (processo, mix, público ou período) antes de replicar qualquer prática.

> **Limitação:** Comparação descritiva desta amostra. Composição dos grupos, valores ausentes e fatores externos podem explicar diferenças; não há comprovação causal.

Suporte amostral (regra prática, não certeza estatística): **moderada** · n = 115; amostra média, margens de erro relevantes

Concentração de receita por produto

Prioridade alta

EVIDÊNCIA

- "Treinamento" responde por 60,7% da soma de "receita" (n=95 linhas).
- O maior de 5 grupos soma 60,7%.

DESCOBERTA

- A soma está distribuída de forma desigual entre os grupos, na base de cálculo atual.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- A concentração pode refletir o tamanho real de cada grupo no negócio ou diferenças de cobertura dos dados. Não testado.

IMPACTO POTENCIAL

Uma variação em "Treinamento" move a soma total de forma desproporcional: cada 10% de variação ali equivale a 6,1% do total, por aritmética.

RECOMENDAÇÃO

Para decisões de gestão: avaliar o risco de depender de poucos grupos e definir um acompanhamento específico para eles.

> **Limitação:** Comparação descritiva desta amostra. Composição dos grupos, valores ausentes e fatores externos podem explicar diferenças; não há comprovação causal.

Suporte amostral (regra prática, não certeza estatística): **maior** · n = 509; amostra grande para esta análise

Média de receita difere entre grupos de produto

Prioridade alta

EVIDÊNCIA

- "Treinamento": média 4.134, mediana 3.215, n=95, IC95% aprox. 2.376 a 5.893.
- "Módulo Extra": média 105,0, mediana 104,7, n=87, IC95% aprox. 72,8 a 137,2.
- Diferença entre médias: 4.029. Grupos comparados: 5 com n ≥ 10 (de 5).

DESCOBERTA

- Os intervalos de confiança aproximados não se sobrepõem: a diferença observada é maior do que a variação esperada só por amostragem, nesta base.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Uma diferença entre grupos não mostra o que a causa. Pode vir de mix de produtos, porte do cliente, período ou outras variáveis não incluídas. Nenhuma foi testada.
- A média é sensível aos 55 valores atípicos mantidos na base. Compare também as medianas (Treinamento: 3.215; Módulo Extra: 104,7) ou ligue a exclusão de atípicos.

IMPACTO POTENCIAL

A diferença de 4.029 entre as médias merece investigação de contexto antes de orientar decisões de gestão. Maior valor da métrica não significa melhor desempenho.

RECOMENDAÇÃO

Para decisões de gestão: investigar com a área responsável o que diferencia o grupo de maior média observada (processo, mix, público ou período) antes de replicar qualquer prática.

> **Limitação:** Comparação descritiva desta amostra. Composição dos grupos, valores ausentes e fatores externos podem explicar diferenças; não há comprovação causal.

Suporte amostral (regra prática, não certeza estatística): **moderada** · n = 87; amostra média, margens de erro relevantes

receita cresce ao longo do tempo

Prioridade alta

EVIDÊNCIA

- 20 meses completos analisados (1 parcial(is) excluído(s)).
- Soma por mês: média dos 3 primeiros 9.548; dos 3 últimos 58.298 (+510,6%).
- Registros por mês: 7,33 → 44,0. Valor médio por registro: 1.451 → 1.318.
- Inclinação linear: +3.146 por mês; r = 0,77 (IC95% 0,50 a 0,91).

DESCOBERTA

- A soma por mês cresce de forma consistente com uma reta (o IC95% de r não inclui zero).
- A comparação acima separa efeito de volume (registros) e de valor médio por registro.

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Variações podem vir de sazonalidade, campanhas, mudanças de preço ou de cadastro. Com 20 períodos não é possível separar sazonalidade de tendência.

IMPACTO POTENCIAL

Entre o início e o fim da série, a soma por mês passou de 9.548 para 58.298. Extrapolar essa reta para períodos futuros não é recomendado sem validar o que mudou.

RECOMENDAÇÃO

Para decisões de gestão: acompanhar o indicador por período e confirmar com a área responsável o que mudou entre o início e o fim da série.

> **Limitação:** Comparação descritiva desta amostra. Composição dos grupos, valores ausentes e fatores externos podem explicar diferenças; não há comprovação causal.

Suporte amostral (regra prática, não certeza estatística): **baixa** · 20 períodos completos; poucas observações para tendência

Variáveis numéricas que andam juntas

Prioridade média

EVIDÊNCIA

- quantidade × desconto_pct: Pearson 0,63 (IC95% 0,57 a 0,68), Spearman 0,60, n=473.

DESCOBERTA

- Nestas linhas, os valores dessas colunas variam juntos (mesma direção para Pearson e Spearman).

INTERPRETAÇÃO · HIPÓTESE NÃO TESTADA

- Correlação não é causalidade. Uma coluna pode ser calculada a partir da outra (relação mecânica), ou ambas dependerem de um terceiro fator. Nenhuma dessas explicações foi testada.

IMPACTO POTENCIAL

Serve para escolher o que investigar. Não sustenta, por si só, a decisão de mexer em uma variável para mudar a outra.

RECOMENDAÇÃO

Antes de agir, checar se as colunas são definidas uma pela outra. Se não forem, testar a relação com um experimento ou com comparação controlada por outras variáveis.

> **Limitação:** Correlação não implica causalidade. Pares usam somente valores válidos; variáveis externas e relações derivadas não foram controladas.

Suporte amostral (regra prática, não certeza estatística): **maior** · n = 473; amostra grande para esta análise

Visão geral

LINHAS NA BASE	DUPLICATAS ENCONTRADAS
509	9 · 1,8%

CÉLULAS AUSENTES	ALERTAS
0,7%	9

Colunas

COLUNA	TIPO INFERIDO	PREENCHIDO	AUSENTES	ÚNICOS	OBSERVAÇÕES
id_pedido	id	509	0 · 0,0%	500	–
data_pedido	data	509	0 · 0,0%	313	datas futuras; formato dia/mês assu
regiao	categórica	505	4 · 0,8%	6	espaços extras; variações de escrita
canal	categórica	509	0 · 0,0%	3	–
produto	categórica	509	0 · 0,0%	5	–
segmento	categórica	509	0 · 0,0%	3	–
quantidade	numérica	509	0 · 0,0%	8	texto em coluna nume; valores negativos
preco_unitario	numérica	509	0 · 0,0%	5	–
desconto_pct	numérica	475	34 · 6,7%	14	–
receita	numérica	509	0 · 0,0%	500	–

Alertas por gravidade

Gravidade é uma regra prática do app: depende da proporção de linhas afetadas.

- média — **data_pedido** · datas futuras
  2 datas posteriores a hoje · linhas 151, 378
- média — **regiao** · categorias inconsistentes
  2 categoria(s) escrita(s) de mais de uma forma
  "Sudeste" (195) · "sudeste" (26)
  "Sul" (96) · "SUL " (8)
- média — **quantidade** · tipo misto
  2 valores não numéricos (ex.: "dez") · linhas 58, 302
- média — **quantidade** · negativos
  3 valores negativos (mín. -1)
- média — **desconto_pct** · ausentes
  34 linhas sem valor (6.7%)
- média — **(linha inteira)** · duplicatas
  9 linhas idênticas a outra anterior (1.8%) · linhas 502, 503, 504, 505, 506, 507, 508, 509, 510
- baixa — **regiao** · ausentes
  4 linhas sem valor (0.8%)
- baixa — **regiao** · espaços
  8 valores com espaços no início ou fim
- baixa — **quantidade** · valor-sentinela
  Valor -1 aparece 3 vezes; pode ser código de "sem informação" (não confirmado)

Valores atípicos por coluna numérica

Regra de Tukey, sobre a base sem duplicatas (se a exclusão estiver ligada). Atípico não significa erro.

COLUNA	CERCA INFERIOR	CERCA SUPERIOR	ATÍPICOS	EXTREMOS (3×)	PESO NA SOMA	MAIORES (LINHA)
receita	-1.406	2.780	55 de 509	20	52,4%	74.970 (333), 45.497 (416), 15.687 (167), 6.361 (195), 6.278 (499)

Limitações e exclusões

Lista gerada a partir do que foi de fato calculado nesta execução.

- Base de cálculo: 509 de 509 linhas lidas; para "receita", 509 linhas válidas, atípicos mantidos.
- 9 duplicatas idênticas foram mantidas nos cálculos (exclusão desligada).
- Os resultados descrevem somente o arquivo carregado. Nenhum benchmark externo, meta ou dado de mercado foi usado ou inventado.
- Todas as relações apresentadas são associações observadas. Nada neste relatório demonstra causa e efeito.
- Valores ausentes são reconhecidos por: vazio, null, NA, N/A, NaN, -, –, n/d, s/d, none, nulo, #N/A. Outro código de ausência seria tratado como valor.
- Números aceitam formato brasileiro (1.234,56) e internacional (1,234.56). Um valor como "1.234" é lido como 1,234, não como 1234.
- Datas com dia e mês ambíguos (ex.: 03/04/2025) seguem o formato indicado pelas outras datas da coluna; sem indício, assume-se dia/mês.
- Outliers usam a regra de Tukey (1,5 × amplitude interquartílica). É um critério estatístico, não um teste de erro.
- Intervalos de confiança de médias usam aproximação normal ($n \geq 10$) e os de correlação usam a transformação de Fisher. São indicativos, não testes formais de hipótese.
- Níveis de suporte por tamanho de amostra (menos de 30 baixa, 30 a 199 moderada, 200 ou mais maior) são uma regra prática do app, não um resultado estatístico.
- Série temporal agregada por mês. Períodos parciais nas pontas (tolerância de 3 dias) ficam fora da tendência. Datas futuras (2) foram ignoradas na série.
- Colunas sem análise estatística (texto livre, identificador ou vazias): id_pedido.
- O que um dado ausente, atípico ou inconsistente significa para o negócio só pode ser confirmado com quem conhece o processo de origem.

Transformações e metodologia

Duplicatas: mantidas. Atípicos: mantidos.

- Nenhuma correção de coluna.

Linhas removidas da base: nenhuma